



1. Papel dos Pesos (w)

Os **pesos** controlam a **importância de cada entrada** (x) no resultado da soma.

- Um peso alto **valoriza mais** a entrada.
- Um peso baixo ou negativo **desvaloriza ou inverte** a influência da entrada.

Exemplo:

txt

CopiarEditar

Entrada $x_1 = 0.8$

Peso $w_1 = 2.0$

→ Contribuição: $0.8 * 2.0 = 1.6$

Se outro input tiver peso -1.0:

txt

CopiarEditar

$x_2 = 0.5, w_2 = -1.0 \rightarrow -0.5$



2. Papel do Bias (b)

O **bias** funciona como um "ajuste fino" na equação.

Ele **desloca o valor da soma ponderada**, ajudando o modelo a se ajustar melhor.

Sem bias, a rede pode ficar muito limitada — imagine que todos os neurônios só disparam se a soma exata for 0.

Com bias, a rede aprende a **deslocar o ponto de ativação**:

ini

CopiarEditar

$z = \sum(w_i * x_i) + b$

Bias \approx intercepto de uma reta:

$y = mx + b \rightarrow b$ define onde a reta cruza o eixo y.

3. Como São Definidos Pesos e Bias?

No início, eles são **valores aleatórios pequenos**.

Depois, o modelo aprende os melhores valores durante o **treinamento** com base em erros cometidos.

Etapas:

1. **Inicialização:**
Pesos e bias começam com números aleatórios (normalmente próximos de zero).
2. **Forward pass:**
A entrada percorre a rede e produz uma saída.
3. **Erro:**
Compara-se a saída real com a saída esperada (target).
4. **Backpropagation:**
Calcula-se o gradiente do erro em relação a cada peso/bias.
5. **Atualização:**
Pesos e bias são ajustados via **algoritmos de otimização**, como:
 - Gradient Descent
 - Adam
 - RMSprop

Fórmula de atualização:

go

CopiarEditar

$$w := w - \eta * \partial E / \partial w$$

$$b := b - \eta * \partial E / \partial b$$

- η é a **taxa de aprendizado**
- $\partial E / \partial w$ é o gradiente do erro em relação ao peso



Como Eles Afetam o Resultado?

Vamos ver na prática:

txt

CopiarEditar

$x_1 = 1.0, x_2 = 2.0$

$w_1 = 0.5, w_2 = -1.0$

$b = 0.2$

Soma: $z = (1.0 * 0.5) + (2.0 * -1.0) + 0.2 = 0.5 - 2.0 + 0.2 = -1.3$

Se usarmos função ReLU:

ini

CopiarEditar

$y = \max(0, -1.3) = 0 \rightarrow$ Neurônio desativado

Mas se ajustarmos o **bias para 2.0**:

lua

CopiarEditar

$z = 0.5 - 2.0 + 2.0 = 0.5$

$\rightarrow y = \max(0, 0.5) = 0.5 \rightarrow$ Neurônio ativado

Se quiser, posso simular esse comportamento com gráficos interativos ou códigos em Python. Quer ver na prática?